

Análisis del Mercado de Alojamientos Turísticos

Madrid, Barcelona y Valencia — Web Scraping de Airbnb y EDA Comparativo

Documentación técnica de los notebooks:
Web_scraping_Airbnb.ipynb
EDA_Fusionado.ipynb

1. Resumen del proyecto

Este proyecto combina dos fases de un mismo flujo de trabajo de análisis de datos: la extracción de datos reales mediante web scraping y el análisis exploratorio de datos (EDA) sobre múltiples fuentes. El objetivo de negocio es comparar la oferta de alojamientos turísticos en Madrid, Barcelona y Valencia entre dos fuentes distintas: un dataset histórico y datos actuales obtenidos directamente de Airbnb, para entender qué explica el precio de un alojamiento y si ambas fuentes son coherentes entre sí.

Notebook 1 — Web_scraping_Airbnb.ipynb: extracción automatizada de anuncios de Airbnb mediante Selenium y BeautifulSoup, distrito a distrito, en las tres ciudades objetivo.

Notebook 2 — EDA_Fusionado.ipynb: limpieza, enriquecimiento y análisis exploratorio conjunto del dataset histórico y del dataset scrapeado, con respuesta a 8 preguntas de negocio.

Fuentes de datos utilizadas

Fuente	Origen	Contenido	Rol en el análisis
alojamientos-turisticos-sample.csv	Dataset proporcionado	10.000 anuncios en bruto, múltiples ciudades	Referencia histórica del mercado
total.csv	Web scraping propio	5.017 registros de Madrid, Barcelona y Valencia	Foto actual del mercado (2026)
inside_Airbnb.csv	Dataset público Inside Airbnb	Variables de anfitrión, licencia y disponibilidad	Enriquecimiento del dataset scrapeado

2. Notebook 1 — Web Scraping de Airbnb

Este notebook implementa un scraper que navega Airbnb de forma automatizada para recopilar anuncios de alojamiento en tres ciudades, sin depender de ninguna API oficial.

2.1 Objetivo

Obtener una muestra representativa y actualizada de anuncios activos en Airbnb para Madrid, Barcelona y Valencia, capturando tanto los datos visibles en el listado de resultados como el detalle de cada anuncio (viajeros, dormitorios, camas y baños), fijando una fecha de entrada y salida común para todos los anuncios.

2.2 Stack tecnológico

- Selenium + ChromeDriver (modo headless) — navegación e interacción con la página, necesaria porque Airbnb carga el contenido de forma dinámica vía JavaScript.
- BeautifulSoup — parseo del HTML ya renderizado para extraer los datos de cada tarjeta de resultado.
- Expresiones regulares — limpieza de texto (precios, número de viajeros, valoraciones) a partir de cadenas no estructuradas.
- csv (módulo estándar de Python) — exportación incremental de resultados por distrito y por ciudad.

2.3 Metodología de extracción

El script sigue el mismo patrón para las tres ciudades, cambiando únicamente la lista de distritos y la URL base:

- 1. Instalación de Chrome y del ChromeDriver correspondiente a la versión instalada, descargado dinámicamente desde el repositorio oficial de Google.
- 2. Construcción de la URL de búsqueda por distrito, fijando fecha de entrada y salida (CHECKIN / CHECKOUT) para que el precio mostrado sea comparable entre anuncios.
- 3. Scroll completo de la página para forzar el lazy load de todas las tarjetas de resultados.
- 4. Paginación: el script avanza hasta un máximo de 15 páginas por distrito, extrayendo el cursor de paginación de la URL del botón "Siguiente".
- 5. Extracción a nivel de tarjeta (listado): ciudad, distrito, room_id, título, precio, nota media y número de reseñas, deduplicando por URL dentro del propio distrito.
- 6. Extracción a nivel de detalle (ficha del anuncio): para cada anuncio recogido, se visita su URL individual y se extraen viajeros, dormitorios, camas y baños mediante espera explícita (WebDriverWait) mientras termina de cargar.
- 7. Exportación a CSV por distrito y, al finalizar cada ciudad, a un CSV consolidado (total.csv).

2.4 Campos capturados por anuncio

Campo	Descripción
ciudad / distrito	Ubicación asignada según la búsqueda que devolvió el anuncio
room_id	Identificador único del anuncio en Airbnb
fecha_entrada	Fecha de check-in usada para fijar el precio (CHECKIN)
título	Título del anuncio
precio	Precio por noche extraído del listado
viajeros / dormitorios / camas / baños	Capacidad del alojamiento, extraída de la ficha individual
nota / reseñas	Valoración media y número de reseñas del anuncio
url	Enlace directo al anuncio

2.5 Cobertura geográfica

Para controlar el volumen de datos, la búsqueda se realizó a nivel de distrito (no de ciudad completa), seleccionando 6 distritos representativos por ciudad:

Madrid	Barcelona	Valencia
Tetuán	Les Corts	Rascanya
Carabanchel	Poblenou	Campanar
Usera	Sants-Montjuïc	L'Olivereta
Valdebebas	Gràcia	Patraix
Puente de Vallecas	Eixample	Benicalap
Chamberí	Horta-Guinardó	Cuatro Carreres

2.6 Resultados y limitaciones

Resultado del scraping

El proceso recogió 5.017 registros en bruto entre las tres ciudades. Al tratarse de una búsqueda por distrito, un mismo anuncio puede aparecer en los resultados de varios distritos colindantes; esta duplicación se cuantifica y se corrige en el Notebook 2 (EDA), donde tras quitar duplicados por room_id quedan 1.808 anuncios únicos.

Limitaciones identificadas

- Al depender del HTML público de Airbnb (sin API oficial), el script es sensible a cambios en la estructura de la página; los selectores (data-testid, XPath) tendrían que revisarse si Airbnb actualiza su interfaz.
- El buscador de Airbnb no limita estrictamente los resultados al distrito consultado, lo que provoca solapamiento entre distritos colindantes (tratado como duplicados en el EDA).
- La captura corresponde a una única fecha de entrada por anuncio, por lo que no permite análisis de estacionalidad de precios.
- El límite de 15 páginas por distrito acota el volumen máximo de anuncios por zona, priorizando cobertura de distritos frente a profundidad en cada uno.

3. Notebook 2 — EDA Fusionado (Datos viejos + Datos nuevos)

Este notebook une en un único flujo de trabajo el análisis exploratorio del dataset histórico y del dataset obtenido por scraping, manteniendo íntegras las transformaciones de ambos análisis originales antes de compararlos.

3.1 Estructura del notebook

Parte	Contenido
Parte 1	EDA sobre el dataset histórico (alojamientos-turisticos-sample.csv)
Parte 2	EDA sobre el dataset nuevo (total.csv), enriquecido con inside_Airbnb.csv
Parte 3	Visualizaciones comparativas y respuesta a 8 preguntas de negocio
Parte 4	Exportación de los datasets limpios (df_clean2.csv, df_clean_viejo.csv, inmuebles_comunes.csv)

3.2 Limpieza del dataset histórico (Parte 1)

- Normalización del campo ciudad (minúsculas, sin espacios) y filtrado a las tres ciudades objetivo: Madrid, Barcelona y Valencia, quedando 5.551 registros de los 10.000 originales.
- Detección de duplicados por apartment_id: 188 duplicados eliminados (5.363 inmuebles únicos).
- Análisis de valores nulos, priorizando la eliminación de registros con nulos en variables críticas (precio, ciudad) frente a variables secundarias (bedrooms, bathrooms).
- Tratamiento de outliers de precio mediante el método del rango intercuartílico (IQR).
- Análisis de correlación con el precio: las variables con mayor peso son huéspedes (0,57), camas (0,45) y dormitorios (0,32); las variables de disponibilidad y de reviews muestran correlación muy débil o negativa.
- Conversión de las variables de disponibilidad (availability_30/60/90/365) a una métrica de ocupación estimada en términos relativos.

3.3 Limpieza y enriquecimiento del dataset scrapeado (Parte 2)

- Cuantificación de duplicados por room_id: de 5.017 registros scrapeados, el 64% eran repeticiones (un mismo anuncio recogido en distritos colindantes), quedando 1.808 anuncios únicos tras eliminar duplicados.
- Verificación de integridad: ningún room_id aparece en más de una ciudad, pero cada anuncio aparece de media en 2,77 distritos distintos, lo que se documenta como limitación en el análisis por distrito.
- Enriquecimiento mediante merge (left join) con el dataset Inside Airbnb, añadiendo variables de confianza y reputación del anfitrión (superanfitrión, tiempo de respuesta, licencia, antigüedad). Se enriquece el 65,9% de los anuncios (1.192 de 1.808).
- Control de calidad post-merge: verificación explícita (assert) de que el número de filas no cambia tras el cruce, comprobando primero la unicidad de la clave de la tabla derecha para evitar multiplicación de filas.
- Renombrado de columnas a español y conversión de tipos (porcentajes a float, fechas a datetime, variables booleanas a enteros).
- Filtrado de outliers de precio y cálculo de la matriz de correlación sobre el dataset ya depurado.

3.4 Visualizaciones generadas

- Histograma y boxplot de la distribución de precios.
- Boxplot de precios por ciudad (Madrid, Barcelona, Valencia), con límite de eje para no distorsionar la escala por outliers.
- Gráfico de precio mediano por distrito, ordenado de mayor a menor.
- Gráfico de precio por tipo de habitación (habitación completa, privada, compartida).
- Gráfico horizontal de precio mediano por tipo de propiedad (top 10 tipologías más frecuentes), mostrando que las propiedades completas con servicios superan los 160 € de mediana frente a menos de 75 € en habitaciones compartidas.

3.5 Preguntas de negocio y resultados clave

1) Inmuebles únicos: dataset original vs. Airbnb

Fuente	Registros en bruto	Inmuebles únicos	% duplicados
Dataset original (3 ciudades)	5.551	5.363	3,4%
Scraping Airbnb	5.017	1.808	64,0%

2) Diferencia de oferta entre fuentes

El dataset original publica 3.555 inmuebles más que el de Airbnb (5.363 frente a 1.808), casi el triple de oferta. Esta diferencia solo se hace evidente tras suprimir duplicados: sobre datos en bruto parecía de apenas un 10%. Conclusión: el scraping capta una fracción del mercado (los primeros resultados del buscador por distrito), no el censo completo de la oferta.

3) Parámetros que mejor explican el precio

En ambas fuentes, las variables estructurales de capacidad explican mejor el precio.

Dataset original: huéspedes (0,57), camas (0,45), dormitorios (0,32), baños (0,12).

Dataset Airbnb: viajeros (0,54), dormitorios (0,40), antigüedad del anfitrión (0,35), licencia turística (0,35), camas (0,21).

4) Coherencia de los factores entre fuentes

Las variables de capacidad coinciden como núcleo explicativo en ambas fuentes con magnitudes similares (0,54–0,57). El dataset Airbnb aporta además factores de confianza y reputación (licencia, antigüedad del anfitrión) no disponibles en el dataset original.

5) Inmuebles presentes en ambas fuentes

El cruce entre ambos datasets ya deduplicados encuentra 11 inmuebles comunes (0,6% del dataset Airbnb). Los precios no coinciden (227,64 € de media en el scraping frente a 105,73 € en el dataset original), explicado por la distancia temporal entre capturas (2019 vs. 2026). Las valoraciones, sin embargo, sí son coherentes una vez normalizada la escala (sobre 100 vs. sobre 5), confirmando que se trata de los mismos alojamientos.

6) Volatilidad de precios y estacionalidad

En términos relativos (coeficiente de variación), el dataset original es notablemente más volátil ($CV \approx 87\%$) que el dataset Airbnb ($CV \approx 49\%$), lo que indica una oferta más heterogénea en el histórico. No es posible evaluar estacionalidad con estos datos: el scraping usa una única fecha de entrada por anuncio y el dataset original solo registra la fecha de carga del anuncio, no la de estancia.

7) Viabilidad de un dataset único combinado

Es posible homogeneizar nombres de columnas y añadir una variable "fuente", pero se opta por mantener ambos dataframes separados: los datos nuevos comparten una única fecha (no permiten estudiar estacionalidad) mientras que los datos históricos sí ofrecen variabilidad temporal.

8) Ranking de inmuebles más caros

En ambas fuentes el precio máximo ronda los 500-700 €/noche, y los inmuebles más caros comparten el mismo patrón: alta capacidad y tipología de vivienda completa, coherente con el análisis de correlación.

3.6 Conclusión del EDA

Conclusión principal

Las dos fuentes de datos son complementarias, no redundantes. El dataset histórico permite dimensionar el mercado y estudiar su evolución temporal; el dataset scrapeado ofrece una fotografía actual y variables de confianza del anfitrión que el histórico no recoge. El solapamiento real entre ambas es mínimo, por lo que no deben fusionarse para ampliar volumen, sino usarse cada una para el propósito que mejor cubre.

4. Habilidades técnicas demostradas

- Web scraping avanzado con Selenium (contenido dinámico, esperas explícitas, paginación por cursor) y parseo de HTML con BeautifulSoup.
- Limpieza y validación de datos: detección y eliminación de duplicados por clave de negocio, tratamiento de nulos por criticidad de variable, y tratamiento de outliers con el método IQR.
- Integración de datos (merge) entre múltiples fuentes con verificación de integridad post-cruce (control de unicidad de claves y de conservación del número de filas).
- Análisis exploratorio de datos (EDA): estadística descriptiva, análisis de correlación y visualización con Matplotlib y Seaborn.
- Pensamiento crítico aplicado a datos: distinción entre magnitudes absolutas y relativas (coeficiente de variación), y detección de cómo la falta de deduplicación puede distorsionar conclusiones de negocio.
- Comunicación de resultados orientada a negocio: respuesta estructurada a preguntas concretas con implicaciones prácticas para el uso de cada fuente de datos.